

**UNIVERSIDADE UNIC – BEIRA RIO I
CIÊNCIA DA COMPUTAÇÃO - 5º SEMESTRE**

**MARCIO BEZERRA CAVALCANTI JUNIOR
JOÃO VITOR VALENTE**

INTELIGÊNCIA ARTIFICIAL NA BORDA

Implementação de um Perceptron em Arquitetura ARM para Monitoramento
Ambiental

Disciplina: Sistemas Digitais e Microprocessadores

Cuiabá — MT

2026

UNIVERSIDADE DE CUIABÁ — UNIC
CURSO DE CIÊNCIA DA COMPUTAÇÃO

INTELIGÊNCIA ARTIFICIAL NA BORDA

Implementação de um Perceptron em Arquitetura ARM para Monitoramento
Ambiental

Trabalho de pesquisa apresentado
à disciplina de Sistemas Digitais e
Microprocessadores do curso de
Ciência da Computação, da
Faculdade UNIC, como requisito
para a obtenção de nota da
Atividade Parcial II.

RESUMO

A proliferação exponencial de dispositivos na Internet das Coisas (IoT) tem evidenciado os gargalos arquitetônicos da dependência exclusiva do processamento centralizado em nuvem (*Cloud Computing*), tais como alta latência, consumo excessivo de banda e vulnerabilidade a falhas de conectividade. Como alternativa estrutural, o paradigma da Inteligência Artificial de Borda (*Edge AI*) propõe a descentralização analítica, realocando o poder de decisão diretamente para sistemas embarcados com recursos computacionais limitados. Neste contexto, este artigo investiga de que forma conceitos introdutórios de Inteligência Artificial podem ser aplicados em microcontroladores utilizando o *framework* Arduino e arquiteturas ARM. Para tanto, apresenta-se o estudo de caso do projeto *KyberMint EcoNode*, um nó IoT de monitoramento ambiental que evoluiu de um modelo simulado de alto nível (*Digital Twin* desenvolvido em Python) para uma implementação nativa de baixo nível orientada a hardware. Utilizando um Raspberry Pi Pico W equipado com processador ARM Cortex-M0+, o sistema implementa um modelo estrutural de rede neural de camada única (Perceptron) programado inteiramente em C++. O algoritmo embarcado é responsável por processar e ponderar localmente os dados multifatoriais de temperatura, umidade e qualidade do ar, calculando o grau de risco ambiental em tempo real. A partir dessa inferência, o sistema realiza o acionamento autônomo de atuadores mecânicos e visuais de alerta, eliminando a obrigatoriedade de comunicação com servidores externos. Os resultados obtidos demonstram a viabilidade técnica e a alta eficiência da aplicação de modelos matemáticos e IA simbólica diretamente na borda. A abordagem reduziu drasticamente o tempo de resposta do sistema e comprovou que a aplicação de lógica inteligente em sistemas digitais e microprocessados garante maior resiliência, segurança operacional e autonomia para infraestruturas críticas.

Palavras-chave: Edge AI; Internet das Coisas; Sistemas Embarcados; Perceptron; Arquitetura ARM.

Sumário

RESUMO.....	3
INTRODUÇÃO	5
REFERENCIAL TEÓRICO	5
METODOLOGIA.....	6
DESENVOLVIMENTO	6
RESULTADOS	7
CONCLUSÃO.....	8
REFERÊNCIAS.....	9

INTRODUÇÃO

Com o avanço da Internet das Coisas (IoT), a quantidade de dados gerados por sensores ambientais cresceu exponencialmente. Tradicionalmente, esses dados são enviados para a nuvem (Cloud Computing) para processamento e tomada de decisão, como demonstrado nas abordagens de telemetria baseadas em dashboards interativos e bancos de dados relacionais. No entanto, essa arquitetura centralizada pode apresentar problemas de latência, consumo excessivo de banda e vulnerabilidade a falhas de conexão.

Como alternativa, o paradigma da Computação de Borda (*Edge Computing*) propõe o processamento de dados o mais próximo possível de onde são gerados. Neste contexto, surge o questionamento: **De que forma os conceitos introdutórios de Inteligência Artificial podem ser aplicados em sistemas embarcados utilizando Arduino e arquiteturas ARM?**

Este trabalho tem como objetivo responder a esta pergunta através do desenvolvimento do *KyberMint EcoNode*, um nó IoT de alto desempenho. O projeto aplica os conhecimentos de Sistemas Digitais e Microprocessadores para transpor um modelo lógico e analítico para dentro de um microcontrolador Raspberry Pi Pico W. Ao implementar um Perceptron nativamente em C++, o sistema é capaz de classificar o risco ambiental em tempo real, acionando atuadores físicos de forma autônoma.

REFERENCIAL TEÓRICO

- **Sistemas Embarcados e Arquitetura ARM:** Microcontroladores baseados na arquitetura ARM, como o Cortex-M0+ presente no RP2040, oferecem um equilíbrio ideal entre baixo consumo de energia e capacidade de processamento. O uso do *framework* Arduino em conjunto com plataformas de compilação como o PlatformIO democratiza o acesso a essas arquiteturas, permitindo a abstração de hardware sem perda significativa de performance.
- **Edge AI e TinyML:** Refere-se à implantação de modelos de aprendizado de máquina em dispositivos com restrições severas de memória e processamento. Ao executar a inferência no próprio dispositivo, garante-se privacidade de dados e respostas determinísticas em tempo real.
- **O Modelo Perceptron:** Introduzido por Frank Rosenblatt em 1958, o Perceptron é a unidade fundamental das redes neurais artificiais. Ele opera recebendo múltiplas entradas (variáveis ambientais), multiplicando-as por pesos sinápticos predefinidos e somando um valor de viés (*bias*). O resultado passa por uma função de ativação (*step function*) que produz uma saída binária (ex: 0 para Normal, 1 para Crítico).

METODOLOGIA

A pesquisa possui natureza aplicada e experimental, dividida em duas fases evolutivas que refletem o ciclo de vida do desenvolvimento de software e hardware:

- **Fase 1 - Modelagem e Simulação (Digital Twin):** Inicialmente, o conceito foi validado utilizando uma *stack* de alto nível com Python, bibliotecas Dash/Plotly para visualização CAD 3D e SQLite3 para armazenamento. Esta fase permitiu compreender o comportamento das variáveis ambientais simuladas através de *Multithreading*.
- **Fase 2 - Implementação em Hardware e Edge AI:** A transição para o ambiente embarcado utilizou o ambiente de desenvolvimento PlatformIO no VS Code, com suporte à *toolchain* ARM. O hardware virtual foi projetado e testado no simulador **Wokwi**, composto por um Raspberry Pi Pico W, sensor DHT22 (Temperatura e Umidade), potenciômetro (simulando o sensor de gás MQ-135), display OLED SSD1306 via I2C, e LEDs/Relés como atuadores.

DESENVOLVIMENTO

O núcleo lógico do *KyberMint EcoNode* afasta-se das simulações de alto nível e implementa uma biblioteca de Inteligência Artificial modularizada nativamente em C++. A arquitetura do sistema foi desenhada no simulador Wokwi, integrando um microcontrolador Raspberry Pi Pico W a um conjunto de sensores e atuadores.

O hardware virtual é composto por um sensor DHT22 para captura de temperatura e umidade, e um potenciômetro ligado ao pino analógico GP26, simulando a variação de um sensor de gás MQ-135. A interface visual é garantida por um display OLED SSD1306 com comunicação I2C, enquanto o controle de saída é feito por LEDs e um pino de relé configurado para acionar exaustores mecânicos.




Figura 1: Diagrama esquemático do hardware simulado no ambiente Wokwi, ilustrando as conexões entre o Raspberry Pi Pico W, sensores ambientais e atuadores.

No escopo do software, em vez de utilizar blocos de condicionais estáticas complexas, a tomada de decisão é delegada à classe Perceptron. A IA foi instanciada com pesos sinápticos específicos para refletir a gravidade de cada variável ambiental: 0.6 para temperatura, 0.1 para umidade, 0.4 para a concentração de gás, e um viés (*bias*) limitador estrito de -40.0.

Durante o ciclo principal de execução (loop), o microcontrolador realiza as leituras do sensor DHT22 e converte a leitura analógica crua do gás (com resolução de 12 bits, variando de 0 a 4095) para uma escala percentual de 0 a 100%. Esses dados normalizados são processados pela função de inferência da IA (`ia_ecoNode.infer(temp, hum, gas_percent)`). O processamento matemático local substitui a necessidade de enviar dados brutos para um servidor, configurando uma verdadeira aplicação de *Edge AI*.

RESULTADOS

A implementação do sistema no ambiente PlatformIO com a arquitetura ARM Cortex-M0+ demonstrou pleno sucesso. O modelo Perceptron mostrou-se altamente eficiente no processamento das variáveis, realizando inferências locais de forma determinística e quase instantânea a cada ciclo do código. Como resultado direto da inferência matemática, a interface visual OLED atualiza em tempo real a telemetria (Temperatura em Celsius, Umidade e Gás em porcentagem) e apresenta o veredito da Inteligência Artificial de forma clara. Quando a combinação de temperatura e gases excede o limiar definido pelos pesos e pelo viés da rede, o display altera seu estado imediatamente de "NORMAL" para "CRITICO!", acionando os pinos digitais que ligam o relé e o LED de alerta.




Figura 2: Interface OLED SSD1306 exibindo a telemetria local e a classificação de estado (NORMAL) inferida autônoma e instantaneamente pelo modelo Perceptron no nó de borda

A modularização do código em C++ (separando a lógica da IA dos comandos de leitura de hardware) não apenas otimizou o uso de memória do Raspberry Pi Pico W, mas também garantiu uma base sólida de Engenharia de Software. O projeto comprova que é viável aplicar IA simbólica e algoritmos matemáticos na borda, eliminando a dependência de dashboards em nuvem para a execução de medidas críticas de segurança, garantindo resiliência contra falhas de rede.

CONCLUSÃO

A investigação proposta por este artigo buscou responder de que forma os conceitos introdutórios de Inteligência Artificial poderiam ser aplicados de maneira prática em sistemas embarcados de recursos restritos, utilizando o *framework* Arduino e a arquitetura ARM. Os resultados experimentais obtidos através do desenvolvimento do projeto *KyberMint EcoNode* validaram com sucesso a hipótese de que modelos matemáticos fundamentais, como o Perceptron de camada única, são perfeitamente viáveis e altamente eficientes quando executados diretamente no ecossistema de hardware de borda (*Edge Computing*).

A evolução do projeto — que se iniciou como um gêmeo digital (*Digital Twin*) de alto nível em Python e evoluiu para um código nativo em C++ estruturado no PlatformIO — evidenciou a importância da engenharia de software aplicada a microcontroladores. Demonstrou-se que a substituição de árvores de decisão condicionais estáticas (if/else) por um motor de inferência linear baseado em pesos sinápticos e viés (*bias*) confere maleabilidade ao sistema. Alterando-se apenas as constantes matemáticas do neurônio artificial, modifica-se completamente o comportamento de classificação do nó IoT sem a necessidade de reestruturar a arquitetura do algoritmo principal.

Do ponto de vista de sistemas digitais e microprocessados, a utilização do processador ARM Cortex-M0+ do Raspberry Pi Pico W mostrou-se ideal para a execução desse paradigma. O dispositivo foi capaz de processar as leituras do sensor climático DHT22 e a conversão analógica de 12 bits do simulador de gás em frações de milissegundos, atualizando instantaneamente a interface HUD do display OLED SSD1306 e controlando de forma determinística os atuadores físicos (relé e LED). Esse comportamento isolado e autônomo elimina o tempo de tráfego de rede e a latência de servidores externos, mitigando riscos de falhas de conexão em monitoramentos de infraestruturas críticas.

Como trabalhos futuros, aponta-se para a expansão deste modelo através do desenvolvimento de redes neurais multicamadas (*Multi-Layer Perceptrons* — MLP) embarcadas para a classificação de padrões mais complexos ou detecção de anomalias temporais mais sutis. Além disso, projeta-se explorar a conectividade Wi-Fi nativa do Raspberry Pi Pico W para que o nó de borda envie apenas o resultado consolidado de suas tomadas de decisão para ecossistemas inteligentes centralizados e orquestradores de agentes de IA em nuvem (como o projeto *Chronos*), unindo com eficiência a autonomia da borda com o poder analítico da computação centralizada.

REFERÊNCIAS

HAYKIN, Simon. *Redes Neurais: Princípios e Prática*. 2. ed. Porto Alegre: Bookman, 2001. (Para fundamentar a parte do Perceptron).

TOULSON, Rob; COOLING, Tim. *Fast and Effective Embedded Systems Design: Applying the ARM mbed*. 2. ed. Newnes, 2016. (Para embasar a arquitetura ARM).

WARDEN, Pete; SITUNAYAKE, Daniel. *TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers*. O'Reilly Media, 2019. (Para fundamentar IA na borda / Edge AI).

Documentação oficial da Raspberry Pi Foundation sobre o microcontrolador RP2040 e a plataforma Pico.

Documentação do PlatformIO e simulador Wokwi utilizados no ambiente de testes.